



ANALYSE BRFSS

*Tableau de bord interactif des comportements
et perceptions de santé (2014-2015)*

Projet de Visualisation de Données

Master 2 Data Science – Évaluation DATAVIZ

Équipe de réalisation

MOUHI Christ-Emmanuel
N'GUESSAN Yakpa Ludivine
KOUIHAON Tosseu Larissa

Encadrements

ANGOUA landry
DZIDZINYO Komla

1 Introduction et problématique

1.1 Contexte

L'enquête Behavioral Risk Factor Surveillance System (BRFSS), menée annuellement par les Centers for Disease Control and Prevention (CDC) aux États-Unis, est la plus importante source de données téléphoniques sur la santé des adultes. Avec plus de 400 000 entretiens par an, elle collecte des informations détaillées et pondérées sur l'état de santé auto-déclaré, les comportements à risque (tabagisme, activité physique, sédentarité), l'accès aux soins et les déterminants socio-démographiques.

Dans un contexte mondial marqué par des inégalités sociales croissantes en matière de santé, l'analyse de ces données est essentielle pour comprendre les déterminants sociaux de la santé, identifier les populations vulnérables et orienter les politiques publiques vers des interventions ciblées et équitables.

1.2 Problématique

Ce projet s'intéresse aux interactions complexes entre facteurs socio-économiques, comportements individuels et état de santé perçu. Il répond aux questions suivantes :

1. Quelles caractéristiques socio-démographiques (âge, sexe, éducation, revenu) sont associées à une meilleure perception de l'état de santé ?
2. Existe-t-il des disparités significatives dans l'accès aux soins selon le niveau socio-économique ?
3. Comment les comportements à risque (tabagisme, sédentarité) sont-ils distribués dans la population ?
4. Quelles interactions existent entre facteurs socio-économiques, comportements à risque et état de santé perçu ?

1.3 Objectifs

- Développer un tableau de bord interactif en R Shiny permettant une exploration dynamique et pondérée des données BRFSS 2014-2015.
- Implémenter des visualisations avancées avec le système graphique `grid` et les objets `grob`.
- Créer des géométries personnalisées via `ggproto` pour répondre à des besoins analytiques spécifiques.

- Identifier les facteurs de risque majeurs et les populations vulnérables afin de proposer des pistes pour les politiques de santé publique.

2 Méthodologie d'analyse

2.1 Données utilisées

Source : fichiers BRFSS 2014 et 2015 (CDC, disponibles sur Kaggle). Taille de l'échantillon : 50 000 observations par année après échantillonnage aléatoire pour optimiser les performances. Variables principales :

- Socio-démographiques : âge (`X_AGE_G` – 6 catégories), sexe (`SEX`), éducation (`EDUCA` – 6 niveaux), revenu (`INCOME2` – 8 catégories).
- Santé : état perçu (`GENHLTH` – 5 niveaux), IMC (`BMI` et `BMI_CAT`).
- Comportements : activité physique (`EXERANY2`), tabagisme (`X_SMOKER3` – 4 catégories).
- Accès aux soins : assurance santé (`HLTHPLN1`).
- Pondération : `X_LLCPT`.

2.2 Pondération des données

Les données BRFSS étant issues d'un plan de sondage complexe, les poids d'enquête (`X_LLCPT`) ont été systématiquement appliqués pour :

- Corriger les biais de non-réponse et de couverture.
- Assurer la représentativité nationale de l'échantillon.
- Obtenir des estimations non biaisées de la population cible.

Formules utilisées :

- Moyenne pondérée : $\mu_w = \frac{\sum (w_i \times x_i)}{\sum w_i}$
- Proportion pondérée : $p_w = \frac{\sum (w_i \times I(x_i=k))}{\sum w_i}$

2.3 Approche analytique

Méthodologie en trois phases :

1. **Descriptive** : distributions univariées, statistiques de tendance centrale et de dispersion, traitement des valeurs manquantes.
2. **Bivariée** : croisements entre variables, tests de significativité (χ^2 , tests t), visualisations conditionnelles.

3. **Multivariée** : identification des interactions, stratification par sous-groupes, analyses de disparités.

2.4 Outils et technologies

Environnement R 4.x. Packages principaux :

- shiny / shinydashboard : interface interactive
- plotly / ggplot2 : visualisations dynamiques et statiques
- grid / gridExtra : compositions graphiques avancées
- dplyr / tidyr : manipulation efficace des données

3 Résultats et interprétations

3.1 Caractéristiques de la population

La population analysée est majoritairement féminine (52%) et vieillissante (25% ont 65 ans et plus). Les disparités de revenu sont marquées, avec une proportion importante de répondants à faible revenu.

L'état de santé perçu est globalement « Bon » (35%), mais 8% le jugent « Mauvais ». Une dégradation significative est observée avec l'âge ($p < 0.001$), confirmant l'impact du vieillissement sur la perception de la santé.

3.2 Accès aux soins

Le taux de couverture par une assurance santé atteint 80% globalement, mais chute à 60% chez les revenus inférieurs à 10k\$. Les non-assurés rapportent deux fois plus souvent une santé « Mauvaise ». Interprétation : l'absence d'assurance limite l'accès aux soins préventifs et contribue à une perception dégradée de la santé, souvent liée à l'anxiété financière.

3.3 Comportements de santé

L'activité physique concerne 70% des répondants globalement, mais seulement 50% chez les 65+. Le tabagisme touche 18% des personnes, avec une prévalence plus élevée chez les bas revenus. L'IMC moyen est de 27 (surpoids), corrélé négativement à l'activité physique.

3.4 Analyses croisées

L'activité physique est fortement associée à une meilleure santé perçue (80% « Bonne » chez les actifs vs 50% chez les inactifs). Les personnes à faible revenu cumulent souvent tabagisme et absence d'assurance, formant un cercle vicieux. Sous-groupes vulnérables identifiés : jeunes adultes à faible revenu (tabagisme élevé), personnes âgées isolées (inactivité), populations à faible éducation (accès limité aux soins).

4 Focus technique : grid et grob

4.1 Analyse structurelle d'un gtable

Un graphique ggplot2 est une table graphique (gtable) composée de :

```
gt <- ggplotGrob(p)
gt$layout # Positions panel, axes, légende
```

Composants principaux : panel (zone des données), axis-b/l (axes), guide-box (légende).

4.2 Manipulation directe avec grid

Exemple : ajout d'annotation personnalisée

```
textGrob("!", x=0.8, y=0.9, gp=gpar(col="red", fontsize=20))
```

Justification : contrôle fin impossible avec les thèmes ggplot standards.

4.3 Composition graphique avancée

Construction manuelle d'une grille 3×2 avec `grid.layout()` et `viewport()`. Interdiction de patchwork/cowplot respectée. Avantages : alignement précis, ajout de fonds personnalisés (`rectGrob`), titre global (`grid.text`).

4.4 Géom personnalisé avec ggproto

Implémentation d'un `geom_health_bar` : *barresavecicnesant(rectGrob+circleGrob+segmentsGrob).Justification : visualisationsymboliqueadapteauxdonneesdesantpublique,integrationtransparentedansggplot2.*

5 Conclusion

Ce projet met en évidence des disparités socio-économiques marquées dans la santé perçue et l'accès aux soins. Les populations à faible revenu cumulent les désavantages : moindre assurance, comportements à risque accrus et perception dégradée de la santé.

Le tableau de bord Shiny permet une exploration interactive puissante et pondérée. Les techniques grid/grob et ggproto offrent un contrôle précis des visualisations, démontrant une maîtrise des outils graphiques avancés.

Perspectives : intégration de données multi-années pour analyser les tendances, ajout de modélisation prédictive et déploiement élargi pour les acteurs de santé publique.